


01 模型吞吐：GPU 前向与完整编码


Thor · CLIP ViT-B/16 · batch=1 · vLLM 驻留但未生成

TF32 FP16

仅 GPU 图像前向



BGR 帧 → 归一化特征




每项预热 80 次，测 3 轮 × 3 秒；柱高为 FPS 中位数，误差线为三轮最小至最大值。

完整编码包含 BGR→RGB、图像预处理、GPU 前向、CPU 特征输出与归一化；两项均不含视频解码。

GPU 前向吞吐不能直接除以 25 作为摄像头容量。数据：2026-09-08 本机实测。

02 摄像头数量增加后，每路还能跑多少帧？


720p 真实 RTSP（约 25 FPS）· 推理上限 30 FPS · 6 帧队列 · 解码与 JPEG 缓存开启



点位为各路平均推理 FPS；每档约 25 秒，摄像头均独立订阅同一条真实视频流。


右图：VLM 单并发、连续五图请求、返回 JSON；混跑 3 路时两种精度均低于每路 25 FPS。

FP16 单路混跑捕获约 864 ms 慢推理、丢 17 帧，因此该点为 24.32 FPS，未剔除。



03 混跑代价：VLM 响应与 CLIP 丢帧


五张实时图片 / 请求 · 单并发持续发送 · 关闭思考 · JSON 输出上限 256 tokens



左图为 VLM 完整响应耗时中位数，每档 6-7 个完成请求；输出长度随画面变化，非固定 token 对照。



右图为约 25 秒测量窗口内所有摄像头合计丢弃的队列帧数，不是网络丢包数。

首次 VLM 请求约 67.97 秒，已作为冷启动单独记录，不计入稳态图表。



04 混跑资源：GPU 忙碌程度与可用内存

GPU 为全局采样利用率，无法按进程拆分；内存为系统 MemAvailable，不是独立显存池



nvidia-smi 进程口径：vLLM 约 82.58 GiB；CLIP 约 0.94 GiB（TF32） / 0.63 GiB（FP16）。

混跑 GPU 采样峰值为 98%；系统可用内存最低约 17.76 GiB，未出现内存不足。

阶段顺序执行、时钟未锁定，缓存未重置；内存曲线不能用于孤立比较两种精度的内存需求。